

Lehrstuhl für Ökonometrie
Prof. Dr. Christoph Hanck
M.Sc. Karolina Gliszczynska

Probeklausur Methoden der Ökonometrie

A1 [20 Punkte]

Betrachten Sie das lineare Regressionsmodell

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u},$$

wobei \mathbf{X} ($n \times k$) vollen Spaltenrang besitzt. Zudem gilt $E(\mathbf{u}|\mathbf{X}) = \mathbf{0}$ und $\text{Var}(\mathbf{u}|\mathbf{X}) = \sigma^2 \mathbf{I}_n$.

- a) Leiten Sie den Kleinste-Quadrate Schätzer $\hat{\boldsymbol{\beta}}$ von $\boldsymbol{\beta}$, sowie dessen Varianz her.
[6 Punkte]

$$\mathbf{X}^* = \begin{pmatrix} \mathbf{X} \\ c\mathbf{X} \end{pmatrix}.$$

- b) Leiten Sie dass der Kleinste-Quadrate Schätzer unter den Annahmen

$$\frac{\mathbf{X}^T \mathbf{X}}{n} \xrightarrow{P} E(\mathbf{X}^T \mathbf{X}) =: \mathbf{S}_{\mathbf{X}^T \mathbf{X}} > 0 \quad \text{und} \quad \frac{\mathbf{X}^T \mathbf{u}}{n} \xrightarrow{P} \mathbf{0}$$

konsistent ist.

[6 Punkte]

- c) Zeigen Sie, dass $\hat{\beta}_2$ bedingt unverzerrt ist.
Hinweis: Falls Sie b) nicht lösen konnten, können Sie im folgenden zeigen, dass der Kleinste-Quadrate Schätzer bedingt unverzerrt ist.
[4 Punkte]
- d) Nennen Sie zwei weitere Eigenschaften der Projektionsmatrix $\mathbf{P}_{\mathbf{X}}$ oder der Residuenmachermatrix $\mathbf{M}_{\mathbf{X}}$ und zeigen Sie diese.
[4 Punkte]

A2 [20 Punkte]

- a) Es sei Y_n eine Folge von reellwertigen Zufallsvariablen und $\mu \in \mathbb{R}$. Definieren Sie die Begriffe „Konvergenz in Wahrscheinlichkeit“ und „Konvergenz im quadratischen Mittel“ von Y_n gegen μ . Sei Y eine reellwertige Zufallsvariable. Definieren Sie „Konvergenz in Verteilung“ von Y_n gegen Y .

[3 Punkte]

- b) Zeigen Sie, dass Konvergenz im quadratischen Mittel die Konvergenz in Wahrscheinlichkeit impliziert.

Hinweis: Benutzen Sie die Markov-Ungleichung:

$$P(|Y_n - \mu| \geq \varepsilon) \leq \frac{E(|Y_n - \mu|^2)}{\varepsilon^2}.$$

[6 Punkte]

- c) Zeigen Sie, dass Konvergenz im quadratischen Mittel die Konvergenz in Wahrscheinlichkeit impliziert.

Bearbeiten Sie die Teilaufgabe (c) in R. Bitte verwenden Sie `set.seed(123)` zu Beginn Ihres Codes.

- c) Sei $(\beta, \gamma) = (2, 0)^T$, $\mathbf{X}_1 = \mathbf{x}_1$ und $\mathbf{X}_2 = \mathbf{1}$, wobei $\mathbf{1}$ ein Vektor von Einsen ist, in Modell (??).

- Erzeugen Sie

$$y_t = 2x_{1t} + 0 + u_t, \quad t = 1, \dots, 25,$$

wobei $x_{1t} \stackrel{u.i.v.}{\sim} \mathcal{U}(0, 1)$ und $u_t \stackrel{u.i.v.}{\sim} N(0, 0.25)$.

- Schätzen Sie β , indem Sie einmal die komplette Matrix \mathbf{X} nutzen ($\hat{\beta}_{\text{OLS}, L}$) und einmal nur den Vektor \mathbf{x}_1 ($\hat{\beta}_{\text{OLS}}$). Speichern Sie beide Ergebnisse.

Hinweis: Das Regressionsmodell der langen Regression ist $y_t = \beta \cdot x_{1t} + \gamma + u_t$.

- Wiederholen Sie das Experiment 1000 mal und berechnen Sie die Stichprobenvarianz der beiden Schätzer. Welcher Schätzer für β hat eine geringere Stichprobenvarianz? Begründen Sie, wieso Ihr Ergebnis in der Theorie zu erwarten war.

[6 Punkte]

- d) Würde sich etwas ändern, wenn der Regressor \mathbf{x}_1 einen Mittelwert von Null hätte? Begründen Sie mit Hilfe von Theorie.

[3 Punkte]

A3 [20 Punkte]

Betrachten Sie das lineare Regressionsmodell

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}, \quad (1)$$

wobei \mathbf{X} ($n \times k$) vollen Spaltenrang besitzt.

- a) Prof. Schranck, ein angesehener Ökonometrieprofessor, grübelt: „Wir haben oft das Problem zu kleiner Datensätze, wir brauchen einfach mehr Daten.“ Er hat eine Idee: „Warum kopieren wir nicht einfach unsere Daten \mathbf{y} und \mathbf{X} ? Das verdoppelt n und unsere Schätzungen werden besser.“ Seine Assistentin Frau Schreckmann wendet ein: „Aber das sind doch dann dieselben Punkte im Streudiagramm, das bringt uns nicht entscheidend weiter!“ Zeigen Sie, dass diese Idee wenig zielführend in Bezug auf den Kleinste-Quadrate Schätzer ist, und dass dieser sich insbesondere gar nicht ändert.

[6 Punkte]

Hinweis: Die neue abhängige Variable und die neuen Regressoren haben nach Kopie Zeilendimension $2n$ und lassen sich dann schreiben als

$$\tilde{\mathbf{y}} = \begin{pmatrix} \mathbf{y} \\ \mathbf{y} \end{pmatrix} \quad \text{und} \quad \tilde{\mathbf{X}} = \begin{pmatrix} \mathbf{X} \\ \mathbf{X} \end{pmatrix}.$$

Bearbeiten Sie die folgenden Teilaufgaben in R. Bitte verwenden Sie `set.seed(123)` zu Beginn Ihres Codes.

- b) Sei $\boldsymbol{\beta} = (\beta_1, \beta_2)^T$ und $\mathbf{X} = (\mathbf{1}, \mathbf{x}_2)$, wobei $\mathbf{1}$ ein Vektor von Einsen ist. Schätzen Sie den Kleinste-Quadrate Schätzer $\hat{\boldsymbol{\beta}}$ von $\boldsymbol{\beta}$ in folgendem Modell

$$y_t = \beta_1 + \beta_2 x_{2t} + u_t, \quad t = 1, \dots, 20. \quad (2)$$

Simulieren Sie dazu jeweils 20 Beobachtungen des Modells wobei $x_{2t} \stackrel{u.i.v.}{\sim} N(0, 1)$ und $u_t \stackrel{u.i.v.}{\sim} N(0, 1)$. Zudem sei $\beta_1 = 1$ und $\beta_2 = 2$.

[3 Punkte]

- c) Eine weitere Assistentin von Prof. Schranck, Frau Karolinger, hat eine weitere Idee: „Wir könnten aber die kopierten Daten für \mathbf{y} und \mathbf{X} jeweils mit einer Konstanten c skalieren, dann bekommen wir wirkliche neue Punkte! Damit gehören dann zu kleine Stichproben der Vergangenheit an!“

Die neue abhängige Variable und die neuen Regressoren haben nach Kopie wieder Zeilendimension $2n$ und lassen sich nun schreiben als

$$\mathbf{y}^* = \begin{pmatrix} \mathbf{y} \\ c\mathbf{y} \end{pmatrix} \quad \text{und} \quad \mathbf{X}^* = \begin{pmatrix} \mathbf{X} \\ c\mathbf{X} \end{pmatrix}.$$

- Speichern Sie die neue Matrix \mathbf{X}^* sowie den neuen Vektor \mathbf{y}^* , die jeweils die alten Beobachtungen \mathbf{X} und \mathbf{y} enthalten sowie die zusätzlichen Beobachtungen $c\mathbf{X}$ und $c\mathbf{y}$. Setzen Sie $c = -3$.
- Schätzen Sie den Kleinste-Quadrate Schätzer $\hat{\boldsymbol{\beta}}^*$ von $\boldsymbol{\beta}^* = (\beta_1^*, \beta_2^*)^T$ im Modell

$$y_t^* = \beta_1^* + \beta_2^* x_{2t}^* + u_t^*, \quad t = 1, \dots, 40 \quad (3)$$

und vergleichen Sie $\hat{\boldsymbol{\beta}}^*$ mit $\hat{\boldsymbol{\beta}}$ aus Modell (2).

[4 Punkte]

d) Berechnen Sie die SSR für beide Regressionen. Multiplizieren Sie die SSR von Modell (2) mit $(1 + c^2)$. Was fällt Ihnen auf?
[3 Punkte]

e) Schätzen Sie für die Regressionen jeweils die Standardabweichung des Koeffizientenschätzers $\hat{\beta}_2$ und $\hat{\beta}_2^*$. Überprüfen Sie den folgenden Zusammenhang

$$\sqrt{\text{Var}(\hat{\beta}_2^*|\mathbf{X}^*)} = \sqrt{(n-2)/(2n-2)} \sqrt{\text{Var}(\hat{\beta}_2|\mathbf{X})}.$$

Prof. Schranck ist begeistert von den Ergebnissen des Experiments: „Die Standardfehler des Koeffizienten verkleinern sich um den Faktor $\sqrt{(n-2)/(2n-2)}$, wenn wir zusätzliche Beobachtungen $c\mathbf{X}$ und $c\mathbf{y}$ hinzufügen! Damit werden doch größere Teststatistiken möglich!“ Kommentieren Sie diese Aussage kritisch.
[4 Punkte]

A4 [20 Punkte]

Der Datensatz *cigarette* (bereits in R eingelesen) enthält für 46 amerikanische Bundesstaaten die jeweils logarithmierten Werte für den durchschnittlichen pro-Kopf Verbrauch (von Personen über 16) an Zigarettschachteln pro Jahr (LNC), den realen Preis pro Schachtel (LNP) und das durchschnittliche reale pro-Kopf-Einkommen ($LN Y$, in 100 US-Dollar). Außerdem ist die Variable *south* enthalten, die den Wert 1 annimmt, wenn es sich um einen Südstaat handelt und 0 sonst.

Betrachten Sie das Modell

$$LNC_t = \beta_1 + \beta_2 LNP_t + \beta_3 LN Y_t + u_t; \quad t = 1, \dots, 46 \quad (4)$$

und bearbeiten Sie folgende Aufgaben:

- a) Schätzen Sie $\beta := (\beta_1, \beta_2, \beta_3)^T$ in obigem Modell und plotten Sie die Residuen der Regression gegen LNP , sowie die Residuen gegen $LN Y$. Was fällt Ihnen auf? Gibt es Hinweise auf eine Verletzung der gewöhnlichen Annahmen des linearen Regressionsmodells?

[5 Punkte]

- b) Testen Sie die $H_0 : \beta_2 = 0$ zum Niveau $\alpha = 0.05$ je einmal unter Verwendung von nicht Heteroskedastie-robusten und Heteroskedastie-robusten Standardfehlern (Typ HC1). Zu welchen Ergebnissen kommen Sie mit Hilfe der Tests?

[5 Punkte]

- c) Betrachten Sie nun

$$LNC_t = \beta_1 + \beta_2 LNP_t + v_t; \quad t = 1, \dots, 46. \quad (5)$$

Führen Sie die OLS-Regression für Modell (5) getrennt für die Südstaaten und die übrigen Staaten der USA durch. Benutzen Sie dafür jeweils die Datensätze *cigarette.sued* und *cigarette.ohne.sued* (bereits in R eingelesen).

Überprüfen Sie mit dem Chow-Test, ob der Einfluss des Achsenabschnitts und des Preises auf den Zigarettenkonsum in den Südstaaten und den übrigen Staaten gleich ist.

[6 Punkte]

- d) Berechnen Sie die Hebelwirkung (Leverage) für Modell (4) (R-Befehl *hatvalues()*). Entfernen Sie alle Beobachtungen, deren Leverages mehr als 3 mal so groß sind wie das arithmetische Mittel über alle Leverages. Schätzen Sie die Koeffizienten des Modells mit dem bereinigten Datensatz erneut. Vergleichen und interpretieren Sie.

[4 Punkte]